

Kaggle Higgs boson machine learning challenge

Koichi Hasegawa

2026 年 2 月 24 日

1 方針

1.1 パラメーターのチューニング

今回は以下のパラメーターをチューニングした。

- layer number : 2, 3 → 3
- dropout : 0.1, 0.2, 0.3 → 0.3
- learning rate : 5e-4, 1e-4, 1e-5 → 5e-4
- weight decay : 5e-4, 1e-4, 1e-5 → 1e-5
- batch size : 512, 1024, 2048 → 1024
- activation function : ReLU, gelu, LeakyReLU → gelu
- base units : 64, 128, 256 → 256

1.2 データの前処理

あらかじめ importance.ipynb で、特徴量の重要度をソートし、上位 15 個の特徴量を選択した。選んだ特徴量の欠損フラグを追加し、欠損値は中央値で補完した。

1.3 training

training は OOF と 5-fold cross validation を行った。

1. 5-fold cross validation により、training data を 5 分割し、4 分割を training data、1 分割を validation data として training を行う。
2. それぞれの fold で、学習していないデータの予測値を OOF に保存する。
3. 以上を 4 回繰り返し、平均を取り、最終的な予測値を得る。

1.4 modeling

3 層の全結合 NN で activation function は gelu を使用し、間に dropout を入れた。学習は loss function を最小にするように最適化をし、AMS が最大となるモデルを採用するように EarlyStopping を行った。ModelCheckpoint で AMS が最大の時のモデルを model.keras として保存した (AMS_test.ipynb のコメントアウトを外し、model fit の 1 つ目の callbacks をコメントアウトすると保存されるようにした)。ま

た、model の再現のため、imputer と scaler, meta information も保存するようにした (該当部分のコメントアウトを外すと保存される)。

2 ファイルと出力ファイルの説明

- AMS_test.ipynb : 上で述べた内容を全て行い、test データの AMS の評価や kaggle に提出するための csv ファイルを出力する。
- importance.ipynb : 特徴量の重要度を計算し、上位 20 個の特徴量を出力する
- submission.ipynb : AMS_test.ipynb で保存したモデルをロードし、test データの予測値を出力する。model の構造や test データの AMS を確認するならこれを実行すればいい
- best_model : それぞれの fold, seed の AMS が最大となるモデルにおける model.keras, imputer.joblib, scaler.joblib, meta.json が保存されている